

NUMERICKÉ METODY 1

DOC. MGR. VÍT VONDRÁK, PH.D.

Vojtěch Zicha*

18. září 2013 – 18. prosince 2013

OBSAH

1	Lineární iterační metody	1
1.1	Jacobiho metoda	3
1.2	Gaussova-Seidelova metoda	3
1.3	Successive over-relaxation (SOR)	4
2	Výpočet vlastních čísel a vlastních vektorů	4
2.1	Krylova metoda	4
2.2	Charakteristický polynom třídiagonálních matic	5
2.3	Výpočet dominantního vlastního čísla	6
2.4	Metody založené na podobnosti matic	7

1 LINEÁRNÍ ITERAČNÍ METODY

Budeme se zabývat úlohami $Ax = B$, $A \in \mathbb{R}^{n \times n}$, $x \in \mathbb{R}^n$, $b \in \mathbb{R}^n$. Předpokládáme, že A je regulární, poté $x = A^{-1}b$. Přednáška 1
9. října 2013

1.1 DEFINICE. **Iterační metoda** je zobrazení $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ taková, že $x_{n+1} = \Phi(x_n)$, kde posloupnost (x_n) jsou tzv. **postupné aproximace**.

1.2 DEFINICE. Iterační metoda Φ je **konzistentní** se soustavou lineárních rovnic $Ax = b$, jestliže pro $\forall b \in \mathbb{R}^n$ jsou řešení $A\bar{x} = b$ současně i pevným bodem Φ , tj. $\bar{x} = \Phi(\bar{x})$.

1.3 DEFINICE. Iterační metoda Φ je **konvergentní** pro libovolné $b \in \mathbb{R}^n$, jestliže

$$\forall x_0 \in \mathbb{R}^n : \lim x_n = \bar{x}$$

1.4 DEFINICE. Iterační metoda Φ se nazývá **lineární**, jestliže

$$\Phi(x) = Mx + Nb$$

kde $M, N \in \mathbb{R}^{n \times n}$.

*vojtech@zicha.name

1.5 LEMMA. Lineární iterační metoda je konzistentní se soustavou $Ax = b$ právě tehdy, když

$$M = I - NA$$

Důkaz. • Předpokládejme, že metoda je konzistentní. Poté $x = Mx + Nb$ a $Ax = b$.

$$x = A^{-1}b,$$

$$A^{-1}b = MA^{-1}b + Nb$$

$$A^{-1} = MA^{-1} + N$$

$$I = M + NA$$

$$M = I - NA$$

- Z předpokladů víme, že $M = I - NA$. Nechť $\bar{x} = A^{-1}b$.

$$M\bar{x} = I\bar{x} - NA\bar{x}$$

$$M\bar{x} = \bar{x} - Nb$$

$$\bar{x} = M\bar{x} - Nb$$

□

1.6 POZNÁMKA. Možné tvary konzistentních metod:

- $x_{n+1} = x_n - N(Ax_n - b),$
- $W(x_n - x_{n-1}) = Ax_n - b, W = N^{-1}.$

1.7 POZNÁMKA. Označme **chybu n -té aproximace** $e_n = \bar{x} - x_n, \bar{x} = A^{-1}b$. Poté platí $e_n = M^n e_0$.

Důkaz.

$$\bar{x} = M\bar{x} + Nb$$

$$x_n = Mx_{n-1} + Nb$$

$$\bar{x} - x_n = M(\bar{x} - x_{n-1})$$

$$e_n = Me_{n-1} = M(Me_{n-2}) = \dots$$

$$e_n = Me^n$$

□

1.8 VĚTA. Lineární iterační metoda $x_{n+1} = Mx_n + Nb$ je konvergentní právě tehdy, když $\rho(M) < 1$, kde ρ je spektrální poloměr matice, tj. $\max_{i=1,\dots,n} \{|\lambda_i|\}$.

1.9 VĚTA. Nechť $\|\cdot\|_M$ je maticová norma odpovídající vektorové normě $\|\cdot\|_v$. Je-li $\|M\|_M < 1$, pak je lineární iterační metoda $x_{n+1} = Mx_n + Nb$ konvergentní.

Důkaz.

$$0 \leq \|e_n\|_v \leq \|M^n e_0\|_v \leq \|M\|_M^n \cdot \|e_0\|_v$$

Tudíž $n \rightarrow \infty : \|e_n\| \rightarrow 0$. □

1.10 POZNÁMKA. Číslo $-\log \varrho(M)$ nazýváme **řád konvergence**.

1.1 Jacobiho metoda

Nechť:

$$A = L + D + U \quad [L]_{ij} = 0, i \leq j \quad [U]_{ij} = 0, i \geq j \quad [D]_{ij} = 0, i \neq j$$

poté zavádíme lineární iterační metodu zvanou **Jacobiho metoda**:

$$(1) \quad M = -D^{-1}(L + U), N = D^{-1}, [D]_{ij} \neq 0.$$

1.11 POZNÁMKA. Uvažujme i -tou rovnici:

$$\begin{aligned} \sum_{j=1}^n a_{ij}x_j &= b_i \\ a_{ii}x_i + \sum_{j=1 \wedge j \neq i}^n a_{ij}x_j &= b_i \\ a_{ii}x_i &= - \sum_{j=1 \wedge j \neq i}^n a_{ij}x_j + b_i \\ x_i &= -\frac{1}{a_{ii}} \sum_{j=1 \wedge j \neq i}^n a_{ij}x_j + \frac{b_i}{a_{ii}} \\ x_{in+1} &= -\frac{1}{a_{ii}} \sum_{j=1 \wedge j \neq i}^n a_{ij}x_{jn} + \frac{b_i}{a_{ii}} \end{aligned}$$

1.2 Gaussova-Seidelova metoda

1.12 POZNÁMKA. Vyjděme z Jacobiho metody:

$$\begin{aligned} x_i &= -\frac{1}{a_{ii}} \sum_{j=1 \wedge j \neq i}^n a_{ij}x_j + \frac{b_i}{a_{ii}} \\ x_{in+1} &= -\frac{1}{a_{ii}} \left(\sum_{j=1}^{i-1} a_{ij}x_{jn+1} + \sum_{j=i+1}^n a_{ij}x_{jn} \right) + \frac{b_i}{a_{ii}} \end{aligned}$$

Tento předpis poté definuje lineární iterační metodu zvanou **Gaussova-Seidelova metoda**:

$$(2) \quad M = -(D + L)^{-1}U, N = (D + L)^{-1}$$

1.3 Successive over-relaxation (SOR)

1.13 POZNÁMKA. Upravme Gauss-Seidelovu metodu:

$$x_i = -\frac{1}{a_{ii}} \sum_{j=1 \wedge j \neq i}^n a_{ij} x_j + \frac{b_i}{a_{ii}}$$

$$x_{in+1} = (1 - \omega)x_{in} + \omega \left(\frac{b_i - \sum_{j=1}^{i-1} a_{ij} x_{j,n+1} - \sum_{j=i+1}^n a_{ij} x_{j,n}}{a_{ii}} \right), 0 \leq \omega \leq 2$$

Následující předpis poté definuje lineární iterační metodu zvanou **Successive over-relaxation**:

$$(3) \quad M = -(D + \omega L)^{-1}(\omega U + (1 - \omega)D), N = \omega(D + \omega L)^{-1}$$

Hledáme poté takové ω , aby řád konvergence byl co nejmenší.

ref

2 VÝPOČET VLASTNÍCH ČÍSEL A VLASTÍCH VEKTORŮ

2.1 DEFINICE. Nechť $A \in \mathbb{R}^{n,n}$. Poté $\lambda \in \mathbb{C}$ a $v \in \mathbb{C}^n$ nazveme **vlastní číslo** a příslušný **vlastní vektor** lineárního zobrazení A , pokud

$$Av = \lambda v$$

2.2 DEFINICE. Pod pojmem **charakteristický polynom** matice A nazveme polynom

$$p(\lambda) = \det(A - I\lambda).$$

. Pod pojmem **charakteristická rovnice** matice A nazveme rovnici

$$p(\lambda) = 0.$$

2.1 Krylova metoda

2.3 VĚTA (Cayley-Hamilton). Platí, že $p(A) = 0$.

$$p(\lambda) = \lambda^n + \sum_{i=0}^{n-1} b_i \cdot \lambda_i = 0$$

$$A^n + \sum_{i=0}^{n-1} b_i \cdot A^i = 0$$

$$A^n y + \sum_{i=0}^{n-1} b_i \cdot A^i y = 0$$

$$[A^0 y \quad \dots \quad A^{n-1} y] b = -A^n y$$

$$\tilde{A}b = \tilde{p}$$

2.4 PŘÍKLAD. Sestavte charakteristický polynom matice $A = \begin{bmatrix} 10 & 1 & 1 & 2 \\ 1 & 5 & 1 & 0 \\ 1 & 1 & -5 & 0 \\ 2 & 0 & 0 & -10 \end{bmatrix}$.

$$A^0 y = y$$

$$Ay = \begin{bmatrix} 10 \\ 1 \\ 1 \\ 2 \end{bmatrix}$$

$$A^2 y = A(Ay) = \begin{bmatrix} 106 \\ 16 \\ 6 \\ 0 \end{bmatrix}$$

$$A^3 y = A(A^2 y) = \begin{bmatrix} 1022 \\ 192 \\ 92 \\ 212 \end{bmatrix}$$

$$\tilde{A} = \begin{bmatrix} 1 & 10 & 106 & 1082 \\ 0 & 1 & 16 & 192 \\ 0 & 1 & 6 & 92 \\ 0 & 2 & 0 & 212 \end{bmatrix}$$

$$b = \begin{bmatrix} 2684 \\ -22 \\ -132 \\ 0 \end{bmatrix}$$

$$p(\lambda) = \lambda^4 - 132\lambda^2 - 22\lambda + 2684$$

2.2 Charakteristický polynom třídiagonálních matic

$$T_n = \begin{bmatrix} a_1 & b_1 & \dots & & 0 \\ c_1 & a_2 & b_2 & & \\ & & \ddots & & \\ & & & c_{n-2} & a_{n-1} & b_{n-1} \\ 0 & & & c_{n-1} & a_n \end{bmatrix}$$

$$p_n(\lambda) = \det(T_n - \lambda I) = (a_n - \lambda) p_{n-1}(\lambda) - b_{n-1} c_{n-1} p_{n-2}(\lambda) \quad p_0(\lambda) = 1, p_1(\lambda) = a_1 - \lambda$$

2.5 PŘÍKLAD. Určete charakteristický polynom matice $A = \begin{bmatrix} 1 & -3 & 0 & 0 \\ 4 & 2 & -2 & 0 \\ 0 & 5 & 3 & -1 \\ 0 & 0 & 0 & 2 \end{bmatrix}$.

$$p_0(\lambda) = 1$$

$$p_1(\lambda) = 1 - \lambda$$

$$p_2(\lambda) = (2 - \lambda)(1 - \lambda) + 12 = \lambda^2 - 3\lambda + 14$$

$$p_3(\lambda) = (3 - \lambda)(\lambda^2 - 3\lambda + 14) + 10(1 - \lambda) = -\lambda^3 + 6\lambda^2 - 33\lambda + 52$$

$$p_4(\lambda) = (2 - \lambda)(-\lambda^3 + 6\lambda^2 - 33\lambda + 52) =$$

2.3 Výpočet dominantního vlastního čísla

2.6 DEFINICE. Předpokládejme, že $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$. Poté λ_1 nazýváme **dominantním vlastním číslem**.

Mocninná metoda

Nechť $A \in \mathbb{R}^n$, $\sigma(A)$, a množina vlastních vektorů $\{x_1, \dots, x_n\}$ přísluší vlastním číslům $\{\lambda_1, \dots, \lambda_n\}$. Poté $\forall v_0 \in \mathbb{R}^n : \exists! \alpha_i \in \mathbb{R} : v_0 = \sum_{i=1}^n \alpha_i x_i$. Nechť $v_0 \in \mathbb{R}^n$ takové, že $\langle v_0, x_1 \rangle \neq 0$. Poté konstruujeme iterační proces $v_{k+1} = Av_k$.

2.7 DEFINICE. Nechť $y \in \mathbb{R}^n$ je takové, že $\langle y, x_1 \rangle \neq 0$. Poté číslo $\sigma_k := \langle y, v_k \rangle$ nazveme **Schwartzova konstanta**.

2.8 VĚTA. Podíl Schwartzových konstant konverguje k dominantnímu vlastnímu číslu ($\lim_{k \rightarrow \infty} \frac{\sigma_{k+1}}{\sigma_k} = \lambda_1$).

Důkaz.

$$\begin{aligned} v_{k+1} &= A^{k+1}v_0 \\ v_{k+1} &= A^{k+1} \sum_{i=1}^n \alpha_i x_i = \sum_{i=1}^n \alpha_i A^{k+1} x_i \\ v_{k+1} &= \sum_{i=1}^n \alpha_i \lambda_i^{k+1} x_i \\ \frac{\sigma_{k+1}}{\sigma_k} &= \frac{\langle y, v_{k+1} \rangle}{\langle y, v_k \rangle} = \frac{\langle y, \sum_{i=1}^n \alpha_i \lambda_i^{k+1} x_i \rangle}{\langle y, \sum_{i=1}^n \alpha_i \lambda_i^k x_i \rangle} \\ &\dots \end{aligned}$$

□

2.9 VĚTA (o posunu spektra). Nechť λ je vlastní číslo A a v je odpovídající vlastní vektor. Poté $A - qI$, $q \in \mathbb{R}$ má vlastní číslo $\lambda - q$ a odpovídající vektor v .

Důkaz.

$$(A - qI)v = Av - qv = \lambda v - qv = (\lambda - q)v$$

□

2.4 Metody založené na podobnosti matic

Nechť $A \in \mathbb{R}^{n,n}$ je symetrická matice.

2.10 DEFINICE. Nechť $A, B \in \mathbb{R}^{n,n}$ jsou podobné, pokud existuje regulární matice $T \in \mathbb{R}^{n,n}$ a platí

$$A = TBT^{-1}.$$

2.11 VĚTA. Podobné matice mají stejné spektrum (stejná vlastní čísla).

Důkaz. Nechť λ je vlastní číslo matice A a v je odpovídající vlastní vektor.

$$\begin{aligned} Av &= \lambda v \\ TBT^{-1}v &= \lambda v \\ BT^{-1}v &= \lambda T^{-1}v \\ Bw &= \lambda w \end{aligned}$$

□

2.12 DEFINICE. Řekneme, že matice $Q \in \mathbb{R}^{n,n}$ je ortogonální, pokud

$$Q^{-1} = Q^T.$$

2.13 VĚTA. Q má lineárně nezávislé řádky (resp. sloupce), tvořící ortonormální bázi.

Důkaz.

$$I = Q^T Q = \begin{bmatrix} s_1^T \\ \vdots \\ s_n^T \end{bmatrix} [s_1, \dots, s_n] = \begin{bmatrix} s_1^T s_1 & \cdots & s_1^T s_n \\ \vdots & \ddots & \vdots \\ s_n^T s_1 & \cdots & s_n^T s_n \end{bmatrix} \quad \forall i, j = 1, \dots, n : s_i^T s_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

□

QR algoritmus

2.14 VĚTA. Nechť $A \in \mathbb{R}^{n,n}$ je regulární. Pak existuje horní trojúhelníková matice $R \in \mathbb{R}^{n,n}$ a ortogonální matice $Q \in \mathbb{R}^{n,n}$ takové, že:

$$A = QR.$$

Důkaz.

$$\begin{aligned}
 \tilde{s}_1 &:= s_1^A, s_1^Q = \frac{\tilde{s}_1}{\|\tilde{s}_1\|} \\
 \tilde{s}_k &:= s_{k-1}^A + \sum_{i=1}^{k-1} \alpha_{i,k} s_i^Q, s_k^Q = \frac{\tilde{s}_k}{\|\tilde{s}_k\|} \\
 \alpha_{j,k} &= -\frac{\langle s_j^Q, \tilde{s}_j \rangle}{\langle s_k^A, \tilde{s}_j \rangle} = -\frac{\langle s_j^Q, s_j^Q \rangle}{\langle s_k^A, s_j^Q \rangle} \\
 s_1^A &= \|\tilde{s}_1\| s_1^Q \\
 s_k^A &= \|\tilde{s}_k\| s_k^Q - \sum_{i=1}^{k-1} \alpha_{i,k} s_i^Q \\
 A^T &= \begin{bmatrix} s_1^{A^T} \\ \dots \\ s_n^{A^T} \end{bmatrix} = \begin{bmatrix} \|\tilde{s}_1\| & 0 & \dots & 0 \\ \dots & \ddots & & \dots \\ -\alpha_{1,n} & \dots & -\alpha_{n-1,n} & \|\tilde{s}_n\| \end{bmatrix} \begin{bmatrix} s_1^{A^T} \\ \dots \\ s_n^{A^T} \end{bmatrix} = R^T Q^T \Rightarrow QR = A
 \end{aligned}$$

□

2.15 VĚTA. Necht $A \in \mathbb{R}^{n,n}$ je symetrická pozitivně definitní matice a posloupnost matic (A_k) je definovaná $A_0 = A, A_{k+1} = Q_k^T A_k Q_k = R_k Q_k$, kde $A_k = Q_k R_k$. Pak

$$\lim A_k = D,$$

kde D má na diagonále vlastní čísla.

Givensovy rotace

Hledáme třídiagonální matici $T = Q^T A Q$ pomocí otočení $Q = R_1 \cdots R_m$, kde

$$R_{i,j}^\varphi = \begin{bmatrix} \cos \varphi & \sin \varphi \\ -\sin \varphi & \cos \varphi \end{bmatrix}.$$

Matice $R_{p,q,r}$ nuluje prvek na pozici $[A]_{q,r}$ se změnou řádku p, q . Pro prvky platí

$$\begin{aligned}
 0 &= \sin \varphi \cdot A_{pr} + \cos \varphi \cdot A_{qr} \\
 \sin \varphi &= -\frac{A_{qr}}{\sqrt{A_{pr}^2 + A_{qr}^2}} \\
 \cos \varphi &= \frac{A_{pr}}{\sqrt{A_{pr}^2 + A_{qr}^2}}
 \end{aligned}$$

Lanczosova metoda

Hledáme symetrickou třídiagonální matici T pomocí posloupnosti podobnostních transformací $T = Q^T A Q$, kde Q je ortogonální maticí.

$$\begin{aligned}
 [s_1^Q, \dots, s_n^Q] T &= A [s_1^Q, \dots, s_n^Q] \\
 s_{k-1}^Q b_{k-1} + s_k^Q + s_{k+1}^Q b_k &= A s_k^Q \\
 \langle s_k^Q, s_{k-1}^Q \rangle b_{k-1} + \langle s_k^Q, s_k^Q \rangle a_k + \langle s_k^Q, s_{k+1}^Q \rangle b_k &= \langle s_k^Q, A s_k^Q \rangle \\
 a_k &= \langle A s_k^Q, s_k^Q \rangle \\
 \langle s_{k+1}^Q, s_{k-1}^Q \rangle b_{k-1} + \langle s_{k+1}^Q, s_k^Q \rangle a_k + \langle s_{k+1}^Q, s_{k+1}^Q \rangle b_k &= \langle s_{k+1}^Q, A s_k^Q \rangle \\
 b_k &= \langle A s_k^Q, s_{k+1}^Q \rangle \\
 \langle s_k^Q, s_{k-1}^Q \rangle b_{k-1} + \langle s_k^Q, s_k^Q \rangle a_k + \langle s_k^Q, s_{k+1}^Q \rangle b_k &= \langle s_k^Q, A s_k^Q \rangle \\
 a_k &= \langle A s_k^Q, s_k^Q \rangle \\
 s_{k+1}^Q &= \frac{1}{b_k} \left((A - a_k I) s_k^Q - b_{k-1} s_{k-1}^Q \right) = \frac{r_k}{\|r_k\|} \\
 r_k &= (A - a_k I) s_k^Q - b_{k-1} s_{k-1}^Q
 \end{aligned}$$